OCR検索可能PDF変換Webアプリ - 完全仕様書

バージョン: 1.0.0
最終更新: 2026-1-15
リポジトリ: https://github.com/J1921604/OCR-PDF-Converter
GitHub Pages（UIデモ）: https://j1921604.github.io/OCR-PDF-Converter/

関連ドキュメント:

- 仕様: https://github.com/J1921604/OCR-PDF-Converter/blob/main/specs/001-OCR-PDF-Converter/spec.md
- 技術要件: https://github.com/J1921604/OCR-PDF-Converter/blob/main/specs/001-OCR-PDF-Converter/requirements.md
- 計画: https://github.com/J1921604/OCR-PDF-Converter/blob/main/specs/001-OCR-PDF-Converter/plan.md
- タスク: https://github.com/J1921604/OCR-PDF-Converter/blob/main/specs/001-OCR-PDF-Converter/tasks.md

---

目次

---

1. プロジェクト概要

1.1 背景と目的

スキャンしたPDFファイルは、見た目は文書として認識できても、コンピューターにとっては単なる画像の集合体です。このため、テキスト検索や複製ができず、情報の活用が制限されます。

本アプリケーションの目的:

- スキャンPDFを検索可能なPDFに変換
- ブラウザ内で完結する処理（プライバシー保護）
- 誰でも無料で利用できるWebアプリケーション

1.2 主要機能

1. **PDFアップロード**: ブラウザから直接PDFファイルをアップロード（50MB以下）
2. **OCR処理**: Pythonバックエンドで複数OCRエンジン（OnnxOCR 2025.5、PaddleOCR 2.7.0.3）を並列実行し、最高精度の結果を自動選択
3. **テキストレイヤー生成**: 最良エンジンの結果を元のPDFに透明レイヤーとして埋め込み
4. **複数ページ対応**: 複数ページPDFのバッチ処理とリアルタイム進捗表示
5. **画像ファイル対応**: JPEG、PNG、TIFFファイルを自動的にPDFに変換
6. **検索可能PDF出力**: 検索とコピーが可能なPDFファイルのダウンロード

1.3 技術スタック

レイヤー	技術	バージョン
フロントエンド	React	18.2.0
PDFレンダリング	pypdfium2 (Python)	4.30.0
OCRエンジン1	OnnxOCR (Python)	2025.5
OCRエンジン2	PaddleOCR (Python)	2.7.0.3
PDF生成	pypdf + ReportLab	5.1.0 + 4.2.0
バックエンド	Flask	3.0.0
ビルドツール	Webpack	5.104.1
テスト	Jest + Cypress	29.7.0 + 13.6.0
ホスティング	GitHub Pages (フロントのみ)	-
CI/CD	GitHub Actions	-

1.3.1 OCRエンジン並列処理アーキテクチャ

本システムは、複数OCRエンジンを並列実行し、最高精度の結果を自動選択する独自機構を実装：

処理フロー:

1. UIで複数エンジン選択（OnnxOCR、PaddleOCRのチェックボックス）
2. 各PDFページで選択された全エンジンを並列OCR実行
3. 各エンジンの平均信頼度（confidence）を計算
4. 最も高い平均信頼度を持つエンジンの結果を採用
5. 採用された結果で透明テキストレイヤーを生成

実装位置: backend/main.py L630-L672

統計情報:

- 各エンジンの平均信頼度
- 総テキスト検出数
- 処理ページ数
- 最良エンジン名

この機構により、ドキュメントの種類や品質に応じて最適なOCRエンジンが自動選択されます。

1.3.2 SSL証明書検証エラー対応

企業プロキシ環境やファイアウォール配下で、PaddleOCRがモデルファイルのダウンロード時にSSL証明書検証エラーが発生する場合があります。

エラーメッセージ例:

```
SSLError: [SSL: CERTIFICATE_VERIFY_FAILED] certificate verify failed: self signed certificate in certificate c
hain
```

実装済み対応（backend/main.py L1-L40）:

1. **SSL証明書検証の無効化**

```
import ssl
ssl._create_default_https_context = ssl._create_unverified_context
```

2. **urllib3警告の抑制**

```
import urllib3
urllib3.disable_warnings(urllib3.exceptions.InsecureRequestWarning)
```

3. **環境変数の設定**

```
os.environ['REQUESTS_CA_BUNDLE'] = ''
os.environ['CURL_CA_BUNDLE'] = ''
```

4. **requests.getパッチング**
   - `ensure_paddleocr_available()` 関数内でrequests.getに `verify=False` パラメータを自動注入

この対応により、自己署名証明書や企業内部CAを使用する環境でもPaddleOCRが正常に動作します。

セキュリティ考慮事項:

- この設定はローカル開発環境でのみ使用してください
- プロダクション環境では適切なCA証明書を設定することを推奨します
- モデルダウンロード元（paddleocr.bj.bcebos.com）が信頼できることを確認してください

1.4 プロジェクト構造

```
OCR-PDF-Converter/
├── public/                 # 静的ファイル
│   ├── index.html         # HTMLテンプレート
│   └── manifest.json      # PWAマニフェスト
├── src/                   # ソースコード
│   ├── components/        # Reactコンポーネント
│   │   ├── FileUploader.jsx
│   │   ├── OCRProgress.jsx
│   │   ├── DownloadButton.jsx
│   │   └── App.jsx
│   ├── services/          # ビジネスロジック
│   │   ├── pdfProcessor.js
│   │   └── pdfGenerator.js
│   ├── hooks/             # カスタムReactフック
│   │   ├── useFileUpload.js
│   │   └── useOCR.js
│   ├── utils/             # ユーティリティ関数
│   │   ├── fileValidator.js
│   │   ├── coordinateConverter.js
│   │   └── errorHandler.js
│   ├── styles/            # スタイルシート
│   │   └── main.css
│   └── index.jsx          # エントリーポイント
├── tests/                 # テストファイル
│   ├── unit/             # ユニットテスト
│   ├── integration/      # 統合テスト
│   └── e2e/              # E2Eテスト
├── docs/                  # ドキュメント
│   ├── DEPLOY_GUIDE.md
│   └── 完全仕様書.md
├── specs/                 # 仕様書
│   └── 001-OCR-PDF-Converter/
│       ├── spec.md
│       ├── requirements.md
│       ├── plan.md
│       ├── research.md
│       ├── data-model.md
│       ├── quickstart.md
│       └── tasks.md
├── .github/
│   └── workflows/         # GitHub Actionsワークフロー
│       └── pages.yml
├── package.json
├── webpack.config.js
└── README.md
```

---

2. 機能仕様

2.1 ユーザーストーリー

ユーザーストーリー 1: PDFアップロードとOCR変換 (P1)

優先度: P1（最高優先度 - MVP）

説明: ユーザーはスキャンされたPDFファイルをブラウザからアップロードし、OCR処理を実行して、検索可能なテキストレイヤーを含むPDFをダウンロードできる。

受入基準:

1. PDFファイル（10MB以下）を選択できる
2. ファイル名とファイルサイズが表示される
3. OCR変換ボタンをクリックすると処理が開始される
4. 処理完了後、ダウンロードボタンが表示される
5. ダウンロードしたPDFでテキスト検索（Ctrl+F）が可能

処理フロー:

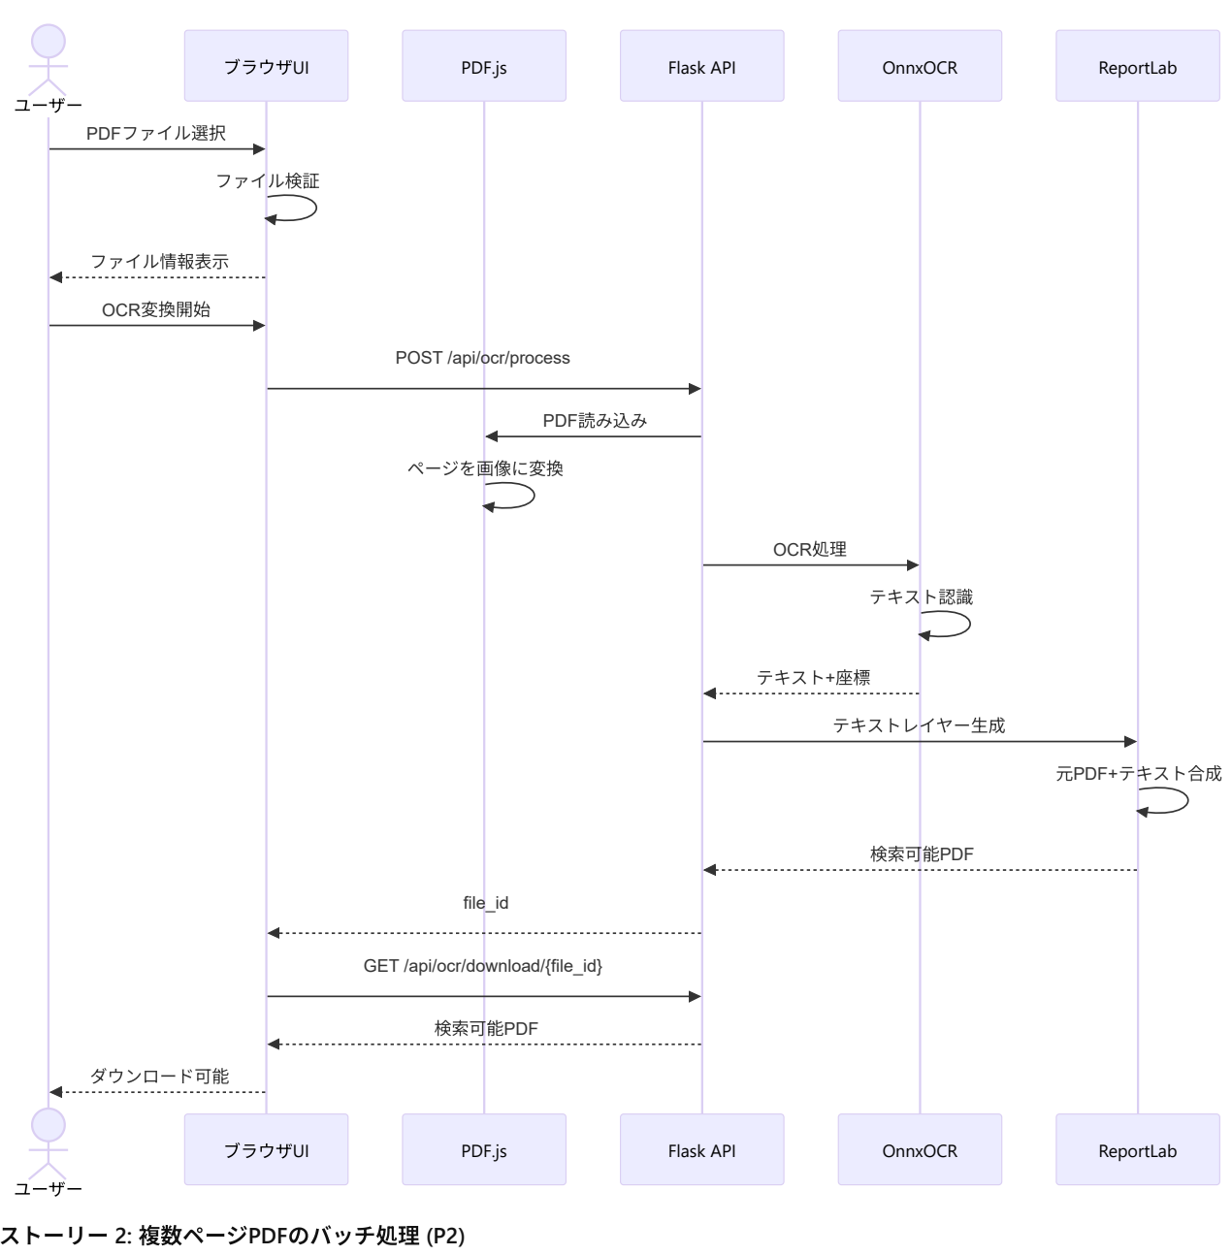

ユーザーストーリー 2: 複数ページPDFのバッチ処理 (P2)

優先度: P2（高優先度）

説明: ユーザーは複数ページを含むPDFファイルをアップロードし、全ページに対してOCR処理を一括実行できる。進捗状況がリアルタイムで表示される。

受入基準:

1. 複数ページPDF（10ページまで）を処理できる
2. 「ページ X/Y 処理中...」形式で進捗を表示
3. 進捗バーが処理状況を視覚的に表示
4. 全ページ完了後、ダウンロード可能
5. 全ページでテキスト検索が可能

並列処理戦略:

- 最大4つの並列ワーカーで処理
- バッチサイズ: 4ページ
- メモリ管理: 処理済みページはメモリから解放

ユーザーストーリー 3: OCR結果プレビューと編集 (P3)

優先度: P3（中優先度 - 将来機能）

説明: ユーザーはOCR処理後、認識されたテキストをプレビュー表示し、誤認識箇所を手動修正してからPDFを生成できる。

受入基準:

1. プレビューボタンでOCR結果を表示
2. テキストボックスで個別に編集可能
3. 修正内容がリアルタイムで反映
4. PDF生成ボタンで最終PDF出力

ユーザーストーリー 4: 画像ファイル対応 (P2)

優先度: P2（高優先度）

説明: ユーザーはJPEG、PNG、TIFF形式の画像ファイルを直接アップロードでき、システムが自動的にPDFに変換してOCR処理を実行する。

受入基準:

1. JPEG、PNG、TIFF画像を選択できる
2. 画像がPDFに自動変換される
3. 変換後のPDFでOCR処理が実行される
4. 画像サイズに応じて適切なPDFページサイズが設定される

ユーザーストーリー 5: 多様なページサイズ対応 (P2)

優先度: P2（高優先度）

説明: ユーザーはA4以外のページサイズ（A3、Letter、Legal、B4等）のPDFをアップロードでき、システムが自動的に適切な解像度でOCR処理を実行する。

受入基準:

1. A3、A4、B4、Letter、Legal、カスタムサイズに対応
2. ページサイズを自動検出
3. 各サイズに応じて300dpi基準で正規化
4. すべてのサイズで正確なOCR処理が可能

2.2 エッジケースとエラーハンドリング

エッジケース	対応
10MBを超えるPDF	エラーメッセージ「ファイルサイズは10MB以下にしてください」を表示
非対応ファイル形式	エラーメッセージ「対応形式: PDF, JPEG, PNG, TIFFのみ」を表示
破損したPDF	エラーメッセージ「PDFファイルが破損しています」を表示
処理タイムアウト	10秒/ページでタイムアウト、再試行を促す
メモリ不足	エラーメッセージ「メモリ不足です。ページ数を減らしてください」を表示
既に検索可能なPDF	メッセージ「このPDFは既に検索可能です」を表示（OCRスキップ）

---

3. 技術要件

3.1 機能要件

ID	要件	優先度
FR-001	PDF/画像ファイル（10MB以下）をブラウザからアップロード	P1
FR-002	PDFページを300dpi基準で画像としてレンダリング	P1
FR-003	OCR処理で日本語テキストと座標情報を抽出	P1
FR-004	透明テキストレイヤーを元のPDFに重ねて合成	P1
FR-005	検索可能PDFのダウンロード	P1
FR-006	複数ページPDFの進捗表示	P2
FR-007	エラー通知の明示的な表示	P1
FR-008	完全クライアントサイド処理（バックエンド不要）	P1
FR-009	ブラウザ内のみで処理（サーバー送信なし）	P1
FR-010	ファイル形式検証とエラーメッセージ	P1
FR-011	多様なページサイズ対応（A3/A4/Letter/Legal等）	P2
FR-012	画像ファイル（JPEG/PNG/TIFF）の自動PDF変換	P2

3.2 非機能要件

3.2.1 パフォーマンス

メトリクス	目標値	測定方法
1ページOCR処理時間	5秒以内（P95）	PerformanceObserver API
10ページOCR処理時間	50秒以内（P95）	自動テスト
ページ読み込み時間	3秒以内（P95）	Lighthouse
メモリ使用量（ピーク）	2GB以下	Chrome DevTools
バンドルサイズ	5MB以下（WASM含む）	webpack-bundle-analyzer

3.2.2 信頼性

- **可用性**: 99.9%（GitHub Pagesの可用性に依存）
- **エラー率**: 1%未満（正常なPDFファイルで）
- **OCR精度**: 90%以上（標準的な印刷品質）

3.2.3 互換性

ブラウザ	最小バージョン	対応状況
Chrome	100+	完全対応
Firefox	100+	完全対応
Edge	100+	完全対応
Safari	15+	完全対応

3.2.4 セキュリティ

- **データ送信**: 外部サーバーへの送信なし
- **ブラウザ内処理**: 全処理をクライアントサイドで完結
- **HTTPS**: GitHub Pagesで自動提供
- **CSP**: Content Security Policy設定済み
- **データ削除**: 処理完了後、メモリから自動削除

3.3 技術制約

- **ファイルサイズ上限**: 10MB
- **対応言語**: 日本語（OCR）、日本語（UI）
- **必須技術**: WebAssembly対応ブラウザ
- **ネットワーク**: 初回ロード時のみ必要（Service Workerでオフライン可能）

---

4. 実装計画

4.1 アーキテクチャ

4.1.1 システムアーキテクチャ

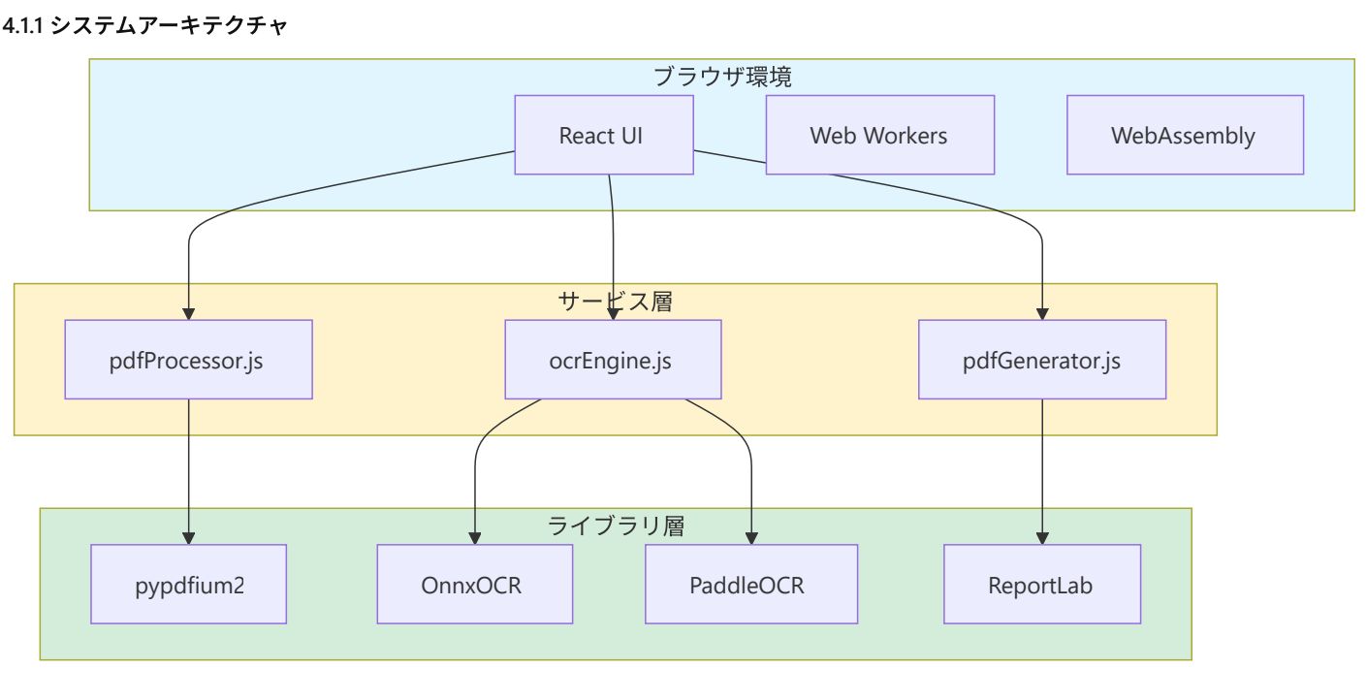

4.1.2 コンポーネント設計

プレゼンテーション層:

- `App.jsx` : ルートコンポーネント、状態管理
- `FileUploader.jsx` : ファイルアップロードUI
- `OCRProgress.jsx` : 進捗バー表示
- `DownloadButton.jsx` : ダウンロードボタン

ビジネスロジック層:

- `pdfProcessor.js` : PDF読み込みと画像変換
- `ocrEngine.js` : OCR処理の実行
- `pdfGenerator.js` : テキストレイヤー生成とPDF合成

ユーティリティ層:

- `fileValidator.js` : ファイル検証
- `coordinateConverter.js` : 座標変換
- `errorHandler.js` : エラーハンドリング

4.2 実装フェーズ

Phase 1: Setup（T001-T014）
- プロジェクト構造作成
- 依存関係インストール
- 設定ファイル作成（webpack、babel、ESLint等）

Phase 2: Foundational（T015-T032）
- ユーティリティ層実装
- サービス層実装
- ユニットテスト作成

Phase 3: User Story 1 - MVP（T033-T050）
- React コンポーネント実装
- カスタムフック実装
- 統合テストとE2Eテスト

Phase 4: User Story 2 - Batch Processing（T051-T059）
- 複数ページ処理実装
- 進捗表示機能
- バッチ処理テスト

Phase 5: User Story 3 - Preview & Edit（T060-T070）
- プレビュー機能（将来実装）
- 編集機能（将来実装）

Phase 6: Image Support（T071-T080）
- JPEG/PNG/TIFF対応
- 画像→PDF変換
- 画像処理テスト

Phase 7: Page Sizes（T081-T088）
- A3/Letter/Legal対応
- ページサイズ自動検出
- 多様なサイズテスト

Phase 8: Polish（T089-T106）
- パフォーマンス最適化
- アクセシビリティ改善
- ドキュメント整備
- GitHub Pagesデプロイ

---

5. データモデル

5.1 主要エンティティ

5.1.1 PDFFile

```
interface PDFFile {
  name: string;            // ファイル名
  size: number;           // ファイルサイズ（バイト）
  mimeType: string;       // MIMEタイプ
  arrayBuffer: ArrayBuffer;  // ファイルデータ
  pageCount: number;      // ページ数
}
```

5.1.2 PDFPage

```
interface PDFPage {
  pageNumber: number;     // ページ番号（1始まり）
  width: number;          // 幅（ポイント）
  height: number;         // 高さ（ポイント）
  canvas: HTMLCanvasElement;  // レンダリング結果
  imageData: ImageData;   // 画像データ
}
```

5.1.3 OCRResult

```
interface OCRResult {
  items: OCRItem[];       // 認識されたテキスト項目
  confidence: number;     // 全体の信頼度（0-100）
  imageHeight: number;    // 画像の高さ（座標変換用）
}

interface OCRItem {
  text: string;           // 認識されたテキスト
  bbox: BoundingBox;      // バウンディングボックス
  confidence: number;     // 信頼度（0-1）
}

interface BoundingBox {
  x0: number;  // 左上X座標
  y0: number;  // 左上Y座標
  x1: number;  // 右下X座標
  y1: number;  // 右下Y座標
}
```

5.1.4 TextLayerItem

```
interface TextLayerItem {
  text: string;        // テキスト内容
  x: number;           // X座標（PDFポイント）
  y: number;           // Y座標（PDFポイント）
  width: number;       // 幅（PDFポイント）
  height: number;      // 高さ（PDFポイント）
  fontSize: number;    // フォントサイズ
  confidence: number; // 信頼度
}
```

5.2 データフロー

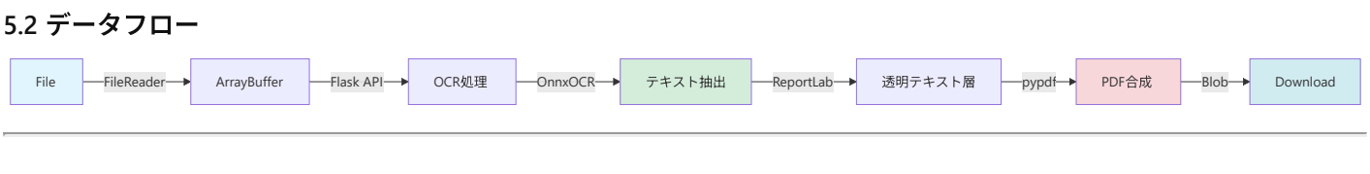

---

6. テスト戦略

6.1 テストピラミッド

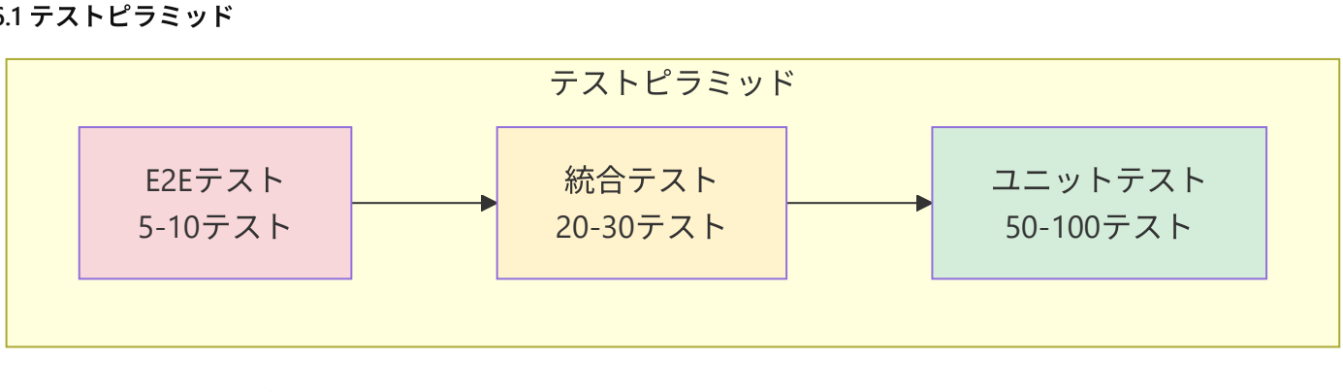

6.2 テストカバレッジ目標

レイヤー	カバレッジ目標
ユニットテスト	80%以上
統合テスト	70%以上
E2Eテスト	主要フロー100%

6.3 テストツール

- **ユニットテスト**: Jest + @testing-library/react
- **統合テスト**: React Testing Library
- **E2Eテスト**: Cypress
- **パフォーマンステスト**: Lighthouse CI

6.4 主要テストケース

ユニットテスト

- fileValidator: MIME type検証、ファイルサイズ検証
- coordinateConverter: 座標変換、フォントサイズ計算
- errorHandler: カスタムエラークラス、エラーメッセージ変換
- pdfProcessor: PDF読み込み、ページレンダリング
- ocrEngine: OCR実行、結果フィルタリング
- pdfGenerator: テキストレイヤー生成、PDF合成

統合テスト

- PDFアップロード → OCR → ダウンロード
- 複数ページPDF処理
- 画像ファイル処理
- エラーハンドリング

E2Eテスト

- 正常系: PDFアップロード → OCR変換 → ダウンロード
- エラー系: 非対応ファイル、サイズ超過
- レスポンシブ: モバイル、タブレット、デスクトップ
- アクセシビリティ: キーボード操作、ARIA属性

---

7. デプロイメント

7.1 デプロイアーキテクチャ

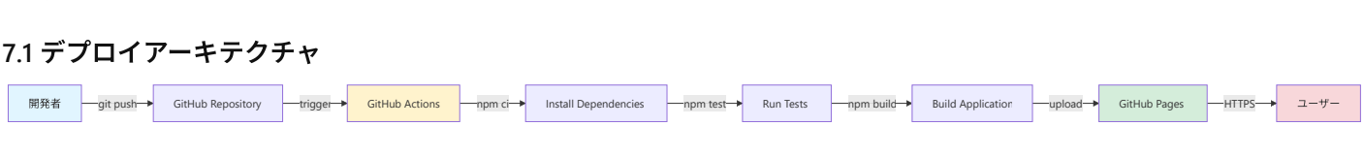

7.2 GitHub Actions ワークフロー

ファイル: `.github/workflows/pages.yml`

トリガー:

- `main` ブランチへのプッシュ
- 手動実行（workflow_dispatch）

ジョブ:

1. **build**:
   - Node.js 18セットアップ
   - 依存関係インストール
   - テスト実行
   - アプリケーションビルド
   - アーティファクトアップロード
2. **deploy**:
   - GitHub Pagesへデプロイ

7.3 デプロイURL

本番環境: https://j1921604.github.io/OCR-PDF-Converter/

7.4 環境変数

変数名	値	用途
PUBLIC_URL	/OCR-PDF-Converter	GitHub Pagesのサブパス
NODE_ENV	production	ビルドモード

---

8. パフォーマンスとスケーラビリティ

8.1 パフォーマンス最適化戦略

8.1.1 バンドル最適化

- **Code Splitting**: Reactコンポーネントの遅延読み込み
- **Tree Shaking**: 未使用コードの削除
- **Minification**: JS/CSSの圧縮
- **Gzip Compression**: GitHub Pagesで自動有効化

8.1.2 OCR処理最適化

- **Web Workers**: OCR処理をメインスレッドから分離
- **並列処理**: 最大4ページを並列処理
- **メモリ管理**: 処理済みページを即座に解放
- **進捗的レンダリング**: ページ単位で結果を表示

8.1.3 キャッシング戦略

- **Service Worker**: アプリケーションのオフライン動作
- **モデルキャッシュ**: OCRエンジンのモデルファイルをキャッシュ（.paddle、.onnx）
- **CDN**: PDF.js workerをCDNから読み込み

8.2 スケーラビリティ

現在の制約:

- 1ユーザーあたり1プロセス（ブラウザ制限）
- 10MBファイルサイズ制限
- GitHub Pages: 無制限トラフィック（ソフトリミット: 100GB/月）

将来のスケーリング:

- Progressive Web App（PWA）化
- IndexedDBでの処理履歴保存
- Web WorkerプールのDynamic Scaling

---

9. セキュリティとプライバシー

9.1 セキュリティ原則

1. **データの外部送信禁止**: 全処理をブラウザ内で完結
2. **HTTPS通信**: GitHub Pagesで自動提供
3. **Content Security Policy**: XSS攻撃対策
4. **依存関係の脆弱性管理**: npm auditで定期チェック

9.2 プライバシー保護

データ処理方針:

- アップロードされたファイルは外部サーバーに送信されない
- 処理中のデータはブラウザメモリ内のみ
- 処理完了後、メモリから自動削除
- Cookie不使用
- Google Analytics等の追跡なし

9.3 CSP設定

```
<meta http-equiv="Content-Security-Policy"
      content="default-src 'self';
               script-src 'self' 'wasm-unsafe-eval' https://cdn.jsdelivr.net;
               worker-src blob:;
               img-src 'self' data: blob:;
               style-src 'self' 'unsafe-inline';">
```

---

10. 運用と保守

10.1 監視とロギング

クライアントサイドロギング:

- エラー発生時のスタックトレース
- パフォーマンスメトリクス（PerformanceObserver）
- ユーザーアクション（ファイルアップロード、OCR開始等）

監視ツール:

- GitHub Actions: ビルド・デプロイステータス
- Lighthouse CI: パフォーマンス・アクセシビリティ監視

10.2 バックアップとリカバリ

コードバックアップ:

- GitHub Repository（自動）
- タグ付けリリース（v1.0.0形式）

ユーザーデータ:

- バックアップ不要（サーバー保存なし）
- ユーザーがダウンロードしたPDFは各自で管理

10.3 メンテナンス計画

定期メンテナンス:

- 依存関係の更新（月次）
- セキュリティパッチ適用（随時）
- パフォーマンステスト（月次）

緊急対応:

- 致命的なバグ: 24時間以内に修正
- セキュリティ脆弱性: 48時間以内にパッチ

10.4 サポートとドキュメント

ドキュメント:

- README.md: プロジェクト概要
- DEPLOY_GUIDE.md: デプロイ手順
- 完全仕様書.md: 本ドキュメント
- tasks.md: 実装タスク一覧

サポート:

- GitHub Issues: バグ報告・機能要望
- GitHub Discussions: 質問・議論

付録

A. 参考リンク

- PDF.js Documentation
- OnnxOCR Documentation
- PaddleOCR Documentation
- pdf-lib Documentation
- React Documentation
- GitHub Pages Documentation

B. 用語集

用語	説明
OCR	Optical Character Recognition（光学文字認識）
WASM	WebAssembly（ブラウザで実行可能なバイナリ形式）
CSP	Content Security Policy（コンテンツセキュリティポリシー）
PWA	Progressive Web App（プログレッシブウェブアプリ）
DPI	Dots Per Inch（解像度の単位）
OnnxOCR	高速CPU推論OCRエンジン（PaddleOCRベース）
PaddleOCR	高精度多機能OCRエンジン

C. 変更履歴

バージョン	日付	変更内容
1.0.0	2026-1-15	初版リリース

プロジェクトリポジトリ: https://github.com/J1921604/OCR-PDF-Converter
ライブデモ: https://j1921604.github.io/OCR-PDF-Converter/
お問い合わせ: GitHub Issues

最終更新: 2026-1-15
バージョン: 1.0.0